

Reliable and Trustworthy Artificial Intelligence

Assignment #2_2021540034

Assignment1 에서와 같이 digital domain 에서 일어나는 adversarial attack 의 경우, differential testing 을 위한 seed 로서의 역할을 할 수 있을 것 같습니다. 각각의 adversarial example 은 victim model 의 내부 기울기를 탈취하여 최적화되기 때문에, 다른 model 은 올바르게 인식하여 (target 에 맞게 인식하여) 서로 다른 출력값을 내놓게 될 것 같습니다. 다만 DeepXplore 의 대상이 되는 DNN models 의 내부 구조가 서로 비슷한 경우 (예를 들면 내부 구조가 같은데 초기화 방법만 다른 채 셋팅된 두 모델) adversarial example 이 targeted 인 경우 여러 모델 모두 하나의 타겟으로 오인식하게 만들 수도 있을 것 같습니다. 또한, Neuron coverage 지표가 adversarial attack 의 대상이 될 seed 를 선정하는 데 도움이 될 것 같습니다. 기존의 adversarial attack 은 test set 의 임의의 부분집합에 대하여 l_p norm 을 기준으로 최적화되어 다루는 공간이 데이터셋의 전체 입력 공간에 비해 매우 적다고 생각합니다. 이 때 neuron coverage 는 seed 의 대상이 될 만한 data 를 고르는데 보다 폭 넓게 탐색할 수 있도록 도와줄 수 있을 것 같습니다.

Adversarial attack 은 입력에 대한 미분값을 구하므로 gradient 값을 늘리도록 optimization method 를 설계한다고 해도 neuron coverage 에 직접적인 영향은 끼치지 못할 것 같습니다.

일반적인 경우에는 하나의 방법만을 사용하는 것이 더 효율적이라고 생각하지만, dataset 이 이루는 공간이 매우 한정적이고 test set 이 이러한 공간에 매우 고르게 분포되어 있는 경우, 두 가지 방법(adversarial attack & DeepXplore)을 합치는 것이 효율성에 도움을 줄 수 있다고 생각합니다. Data 를 조작하여도 모델이 이를 매우 잘 판별할 것인데, DeepXplore 가 모델이 잘 판별하지 못할 공간 속, attackd 의 대상이 될 data 를 찾아내는데 도움을 줄 것이라 생각합니다.

한계점은 분명히 존재합니다. 위에서와 같이 일반적인 경우에 효율적이지 못하다고 생각하고 DeepXplore 의 neuron coverage 방식이, 검증을 위해 모델에게 취약한 test dataset 을 모두 찾는 데에는 아직 한계가 있기 때문입니다. 이러한 한계는 neuron coverage 를 다룬 후속 논문들에서 극복하려는 시도가 이어지고 있습니다.